

Computer vision

computer vision challenge keuzen

Naam : Hussin Almoustafa

Studentnummer : 1776495



February 13, 2023

1 Challenge

Computer Vision speelt een cruciale rol in de moderne gezondheidszorg, met name in de vroegtijdige opsporing en behandeling van ziekten zoals kanker. de opdrachten die ik graag willen pakken is het detecteren en classificeren van kankercellen door middel van anomalie-detectie in de latent space.

Met de hulp van de X-ray borst dataset, kunnen computer vision algoritmen worden getraind om afwijkingen in borstweefsel te detecteren en te classificeren als kankercellen. Hierbij wordt gebruik gemaakt van de principes van de unsupervised machine learning, waarbij de algoritmen worden blootgesteld aan gegevens zonder specifieke labels of categorieën, zodat ze zelf kunnen leren om afwijkingen te identificeren.

Het doel van deze opdracht is om een efficiënte en nauwkeurige anomalie-detectiemethode te ontwikkelen die de mogelijkheid biedt om kanker op vroege stadia te detecteren en te classificeren. Dit is van groot belang omdat vroegtijdige opsporing de overlevingskans en de effectiviteit van de behandeling sterk verhoogt.

Met de ontwikkeling van dergelijke computer vision-algoritmen, kunnen zorgverleners zich meer richten op de behandeling van patiënten in plaats van het uitvoeren van tijdrovende handmatige inspecties. Bovendien kan de nauwkeurigheid en betrouwbaarheid van de diagnose worden verhoogd, waardoor het risico op foutieve diagnoses en onnodige behandelingen wordt verminderd.

De motivatie achter deze opdracht om kankercellen te detecteren en classificeren door middel van anomalie-detectie in de latent space is multi-dimensionaal. Aan de ene kant is er de dringende behoefte aan vroegtijdige opsporing en behandeling van kanker, wat leidt tot verbeterde overlevingskansen en behandelresultaten. Aan de andere kant is er ook de wens om de samenwerking tussen artsen en AI te versterken.

In het kader van het project voor de Intensive Care Unit (ICU) waaraan u werkt, zou de toevoeging van computer vision een waardevolle bijdrage kunnen zijn. Door middel van een dashboard kunnen artsen real-time toegang krijgen tot diagnostische gegevens, waardoor ze snellere en nauwkeurigere beslissingen kunnen nemen.

De toevoeging van computer vision aan het dashboard zou de artsen in staat stellen om de resultaten van de anomalie-detectie van kankercellen te bekijken, waardoor ze in staat zijn om sneller en nauwkeuriger te beslissen over de volgende stappen. Dit versterkt de band tussen artsen en AI, waardoor de samenwerking tussen beide partijen wordt verbeterd.

In feite zou de toevoeging van computer vision aan het dashboard een waardevolle aanvulling kunnen zijn op de bestaande systemen in de ICU, en zou het kunnen bijdragen aan een verbetering van de zorg voor patiënten. Het is daarom een zinvolle en uitdagende op-

dracht om te werken aan de implementatie van computer vision in het ICU-project.

2 Methoden

Voor deze opdracht ik zal volgende technologies gebruiken :

- Vector Quantized Variational AutoEncoder (VQ-VAE)
- Anomaly detection through latent space restoration

2.1 Vector Quantized Variational AutoEncoder (VQ-VAE)

De Vector Quantized Variational AutoEncoder (VQ-VAE) is een machine learning-model dat gebruik maakt van unsupervised learning. Het combineert twee verschillende concepten, die van een Variational Autoencoder (VAE) en Vector Quantization (VQ) om hoogwaardige, compacte weergaven van gegevens te genereren.

Een Variational Autoencoder (VAE) is een type generatief model dat kan worden gebruikt om een compacte weergave van gegevens. Het werkt door een neurale netwerk te trainen om gegevens in een lagere dimensie te coderen spatie en decodeer het vervolgens terug naar zijn oorspronkelijke vorm.

Het encodernetwerk leert de invoergegevens toe te wijzen aan een set parameters, en het decodernetwerk koppelt die parameters terug aan de oorspronkelijke gegevens.

Vector Quantization (VQ) is een techniek die wordt gebruikt om gegevens weer te geven met behulp van een kleinere set vertegenwoordigers vectoren. Het werkt door de gegevens in clusters te verdelen, waarbij elk cluster wordt weergegeven door een enkele vector, het zwaartepunt genoemd. Deze zwaartepunten worden vervolgens gebruikt om het hele cluster weer te geven, in plaats van het individu data punten.

VQ-VAE combineert de sterke punten van zowel VAE als VQ om hoogwaardige en compacte weergaven te genereren van gegevens. Het werkt door de VAE te trainen om de gegevens te coderen en vervolgens VQ te gebruiken om de gegevens te kwantiseren coderingen in een kleinere set discrete representaties. Dit resulteert in een compactere weergave van de gegevens, met behoud van een hoog kwaliteitsniveau.

De VQ-VAE bestaat uit twee hoofdcomponenten: een encoder en een decoder zie figuur[1]. De encoder neemt de invoergegevens op en wijst deze toe aan een lager-dimensionale latente ruimte, terwijl de decoder de latente ruimte opneemt representatie en reconstrueert de oorspronkelijke gegevens. Tussen de encoder en de decoder zit een discrete latente ruimte, die wordt gecreëerd door de latente ruimte te verdelen in een vast aantal gebieden van gelijke grootte of "codeboeken." Elke regio is gekoppeld aan een vast aantal "codes", die worden gebruikt om de gegevens in de latente ruimte.

Een belangrijk kenmerk van de VQ-VAE is dat het een "empirisch" codeboek gebruikt, wat betekent dat de codes geleerd van de gegevens zelf, in plaats van vooraf bepaald door het

model. Hierdoor kan de VQ-VAE aanpassen aan de structuur van de gegevens en meer compacte en representatieve codes leren.

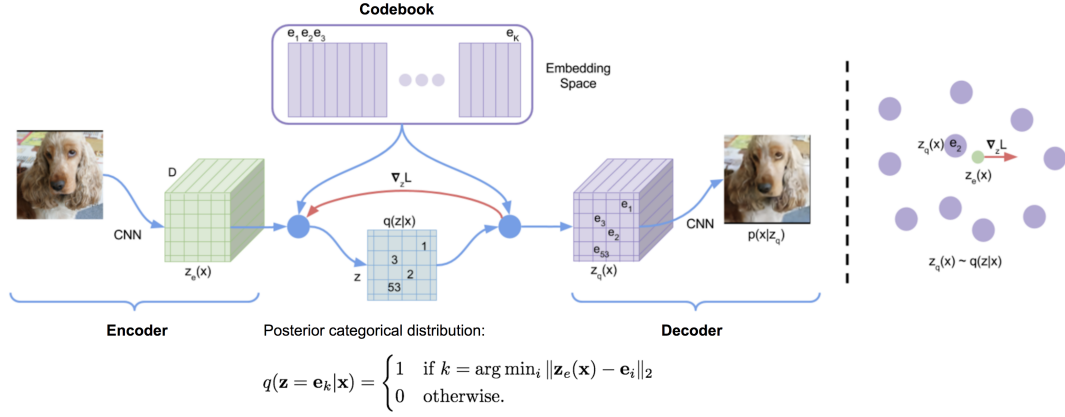


Figure 1: Left: A figure describing the VQ-VAE. Right: Visualisation of the embedding space. The output of the encoder $z(x)$ is mapped to the nearest point e_2 . The gradient $\nabla_z L$ (in red) will push the encoder to change its output, which could alter the configuration in the next forward pass

2.2 Anomaly detection through latent space restoration

In het artikel "Anomaly Detection through Latent Space Restoration" stellen de auteurs een nieuwe benadering voor voor anomaliedetectie met behulp van een out-of-distribution-detectiemethode die dichtheid en op herstel gebaseerde benaderingen combineert met behulp van Vector-Quantized Variational Auto-Encoders (VQ-VAE's). Het VQ-VAE-model leert afbeeldingen te coderen in een categorische latente ruimte. De eerdere distributie van latente codes wordt vervolgens gemodelleerd met behulp van een Auto-Regressive (AR) model.

Vector Quantized Variational Auto-Encoders (VQ-VAE's) zijn een type machine learning-model zonder toezicht dat wordt gebruikt voor anomaliedetectie. Deze modellen coderen waargenomen variabelen in een discrete latente ruimte, in tegenstelling tot een continue ruimte. Dit maakt het genereren van hoogwaardige en gedetailleerde reconstructies mogelijk, en maakt ook de koppeling mogelijk met Auto-Regressive (AR)-modellen, die onafhankelijk de eerdere distributie kunnen leren.

VQ-VAE's zijn gebouwd rond een woordenboek dat K discrete sleutels afbeeldt op een D -dimensionale inbeddingsruimte. Het encodernetwerk wijst waargenomen variabelen toe aan de inbeddingsruimte en de achterkant in VQ-VAE's is categorisch en deterministisch, gedefinieerd als de index van de dichtstbijzijnde inbeddingsvector naar de encoderuitgang. Het decodernetwerk neemt als invoer de dichtstbijzijnde inbedding en leert de waargenomen variabele verdeling te reconstrueren.

De parameters voor zowel encoder- als decoder-netwerken, evenals de inbeddingen, worden geleerd met behulp van back-propagation. De argmin-operator die in de encoder wordt gebruikt, is echter niet-differentieerbaar, dus de gradiënt wordt meestal benaderd met behulp van een straight-through-schatter. Er worden aanvullende termen geïntroduceerd in de VQ-VAE-verliesfunctie om gradiënten aan de inbeddingen te geven en om de encoder te stimuleren om zich te committeren aan inbeddingen.

De eerdere distributie van VQ-VAE wordt geleerd met behulp van een auto-regressief model, waarmee de waarschijnlijkheid van monsters kan worden geschat en afwijkingen kunnen worden geïdentificeerd als monsters met een lage waarschijnlijkheid. Bovendien, aangezien AR-modellen generatief zijn, maken ze de iteratieve bemonstering van één variabele tegelijk mogelijk, een eigenschap die wordt gebruikt om meerdere restauraties te genereren.

Afwijkingsscores worden gebruikt om aan te geven hoe waarschijnlijk het is dat een bepaald monster een afwijking bevat, zie [2]. Deze scores kunnen gebaseerd zijn op dichtheid, gebaseerd op een geschatte waarschijnlijkheid van een steekproef, of op reconstructie gebaseerd, gebaseerd op de veronderstelling dat modellen die zijn getraind op normale gegevens niet in staat zullen zijn om afwijkingen te reconstrueren. In het geval van VQ-VAE's vertalen abnormale regio's zich in ongebruikelijke latente variabelen, waarvoor het AR-model een lage waarschijnlijkheid toekent, dus een steekproefsgewijze anomaliescore wordt afgeleid van de eerdere waarschijnlijkheid geschat door het AR-model.




Figure 2: Sergio Naval Marimont, Giacomo Tarroni— Anomaly detection through latent space restoration using vector-quantized variational autoencoders ,Visualization of restorations and pixel-wise score (<https://arxiv.org/abs/2012.06765>)

3 References

Data:

- Chest X-Ray Images (Pneumonia). (2018, 24 maart). Kaggle. <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia/code>

Papers:

- Neural Discrete Representation Learning deep-learning VAE Neural Discrete Representation Learning Reviewed on Sep 26, 2019 by Jon Haitz Legarreta Gorroño • <https://arxiv.org/pdf/1711.00937.pdf>

- **Anomaly detection through latent space restoration using vector-quantized variational autoencoders** Marimont Tarroni <https://arxiv.org/abs/2012.06765>
- **werk environment** <https://github.com/hassoonsy2/Image-Processing-and-Computer-Vision>